

Aplicação de Morfologia Matemática e Agrupamento K-Means na Segmentação de Imagens Médicas e Naturais

1st João Victor Pereira Vieira
Departamento de Ciência da Computação
Universidade de Brasília (UnB)
Brasília-DF, Brasil
institutodnb@gmail.com

Abstract—Este relatório técnico apresenta a implementação e avaliação de duas técnicas clássicas de Processamento Digital de Imagens (PDI) aplicadas a problemas de segmentação. Na primeira etapa, emprega-se uma sequência de filtragem espacial, limiarização de Otsu e operações de morfologia matemática (abertura, fechamento e análise de componentes conexos) para isolar um candidato a lesão em um exame de tomografia computadorizada (TC) cerebral. Na segunda etapa, utiliza-se o algoritmo de agrupamento k-means para segmentar por cor uma imagem de hortaliças, com a quantidade de clusters determinada algoritmicamente pelo método do cotovelo. Os resultados evidenciam que critérios ingênuos de seleção, como a área bruta de um componente conexo, podem falhar na identificação da estrutura de interesse, sendo necessário incorporar uma medida de forma (compacidade) para discriminar corretamente a lesão de estruturas anatômicas maiores, como o crânio. Discute-se ainda o compromisso entre a escolha estatisticamente ótima do número de clusters e a granularidade semântica desejada na segmentação por cor.

Index Terms—Processamento de Imagens, Morfologia Matemática, Limiarização de Otsu, Componentes Conexos, K-Means, Segmentação por Cor.

I. INTRODUÇÃO

A segmentação de imagens é uma das etapas mais críticas do Processamento Digital de Imagens (PDI), permitindo isolar regiões de interesse a partir de critérios de intensidade, forma ou cor. Suas aplicações abrangem desde o diagnóstico assistido por computador em medicina até a automação de inspeção visual em ambientes industriais e agrícolas. O objetivo central deste trabalho é explorar duas abordagens distintas de segmentação: a primeira fundamentada em morfologia matemática sobre imagens monocromáticas, e a segunda baseada em agrupamento não supervisionado (k-means) sobre o espaço de cor.

O relatório está estruturado em duas frentes principais, conforme os requisitos estabelecidos para o projeto. A primeira (Seção II-A) aborda a identificação de um candidato a tumor em um exame de TC cerebral, através de uma sequência de pré-processamento, limiarização e morfologia matemática. A segunda (Seção II-B) trata da segmentação por cor de uma imagem contendo múltiplas hortaliças, utilizando k-means com seleção automática do número de clusters.

A. Ferramentas e Ambiente de Desenvolvimento

O projeto foi desenvolvido em linguagem Python 3.12, utilizando Jupyter Notebook como ambiente interativo para a orquestração dos testes e renderização visual dos comparativos através da biblioteca Matplotlib (`pyplot`). A biblioteca OpenCV (`cv2`) foi empregada na leitura e conversão de canais de cor, na filtragem espacial (passa-baixas e mediana), na limiarização de Otsu e nas operações de morfologia matemática. Para a etapa de agrupamento por cor, utilizou-se a biblioteca scikit-learn (`sklearn.cluster.KMeans`), além de `sklearn.metrics.silhouette_score` para a análise complementar de qualidade de cluster. O código-fonte completo, incluindo notebooks, módulos e dados de entrada, está disponível publicamente em: <https://github.com/The-Jonas/Image-Segmentation-KMeans-Morphology>.

II. METODOLOGIA, FUNDAMENTAÇÃO TEÓRICA E RESULTADOS

A. Questão 1 — Detecção de Candidato a Tumor via Morfologia Matemática

1) *Pré-processamento e Filtragem*: A imagem de entrada (`brain.jpg`), um corte axial de TC cerebral, foi primeiramente verificada quanto ao número de canais e convertida para escala de cinza quando necessário. Em seguida, aplicou-se uma filtragem sequencial composta por um filtro passa-baixas (média 5×5) seguido de um filtro de mediana (3×3), conforme especificado no enunciado.

O filtro de média atua como um passa-baixas no sentido estrito: a convolução com um kernel uniforme atenua as variações de alta frequência espacial (ruído) e preserva as variações lentas de intensidade. Já o filtro de mediana substitui cada pixel pelo valor mediano de sua vizinhança, sendo robusto a outliers e eficaz contra ruído impulsivo, sem borrar bordas tanto quanto um filtro de média de kernel equivalente.

Visualmente, a textura do tecido cerebral (sulcos e giros) permanece praticamente inalterada após a filtragem (Fig. 1), o que poderia sugerir que o processo é inócuo. Entretanto, essa textura está predominantemente abaixo do limiar de binarização determinado na etapa seguinte, não afetando o




Fig. 1. Sequência de filtragem: (a) imagem em escala de cinza; (b) após filtro passa-baixas; (c) após filtro de mediana.

resultado final. O efeito real da filtragem manifesta-se nas bordas das estruturas de alta intensidade (crânio e candidato a lesão); a binarização direta da imagem sem filtragem prévia produziu 22 componentes conexos espúrios (excluindo o fundo), enquanto a binarização da imagem filtrada produziu apenas 4. Esse resultado demonstra que a contribuição da filtragem não deve ser avaliada pela inspeção visual da imagem em escala de cinza, mas pelo seu impacto quantitativo na etapa de binarização subsequente.

2) *Limiarização de Otsu*: Para a binarização, utilizou-se o método de Otsu, que determina automaticamente o limiar t^* que maximiza a variância interclasse (ou, equivalentemente, minimiza a variância intraclasse) entre os pixels classificados como fundo e objeto, a partir do histograma de níveis de cinza da imagem. Esse método é particularmente adequado ao requisito do enunciado de “analisar o histograma da imagem para achar o melhor limiar”, pois realiza essa análise de forma algorítmica e determinística.




Fig. 2. Histograma de níveis de cinza da imagem filtrada, com o limiar de Otsu indicado ($t^* = 126$).

Para a imagem em estudo, o método convergiu para $t^* = 126$ (Fig. 2). A binarização resultante (Fig. 3) separa nitidamente as estruturas de alta intensidade — o crânio e a região hiperdensa candidata a lesão — do tecido cerebral e do fundo.

3) *Operações Morfológicas e Seleção do Componente de Interesse*: Após a binarização, aplicaram-se sequencialmente as operações morfológicas de abertura (erosão seguida de dilatação) e fechamento (dilatação seguida de erosão), com elemento estruturante elíptico de tamanho 3×3 , visando




Fig. 3. (a) Imagem filtrada; (b) imagem binarizada com o limiar de Otsu.

eliminar pequenas irregularidades de borda decorrentes do processo de binarização (Fig. 4).




Fig. 4. (a) Imagem binarizada; (b) após abertura; (c) após fechamento.

Na etapa de identificação do candidato a tumor, a estratégia inicialmente sugerida — selecionar o componente conexo de maior área — foi testada empiricamente e mostrou-se inadequada para esta imagem. A Tabela I resume as estatísticas dos quatro componentes conexos obtidos (excluindo o fundo).

TABLE I
ESTATÍSTICAS DOS COMPONENTES CONEXOS OBTIDOS

Componente	Área (px ²)	BBox (px)	Compacidade
Crânio	20557	287 × 326	0,22
Candidato a tumor	502	36 × 25	0,56
Artefato 1 (mesa)	540	72 × 123	0,06
Artefato 2 (mesa)	457	66 × 104	0,07

Observa-se que o componente de maior área corresponde ao crânio, uma estrutura anatômica anelar que ocupa aproximadamente 10% da área total da imagem. Mais relevante ainda, um dos artefatos decorrentes da mesa do tomógrafo (área 540 px²) possui área superior à do próprio candidato a tumor (área 502 px²), invalidando o critério de maior área como discriminador confiável.

Para contornar essa limitação, adotou-se como critério de seleção a *compacidade* de cada componente, definida como a razão entre sua área e a área de sua caixa delimitadora (*bounding box*):

$$C = \frac{\text{Área}}{\text{Largura} \times \text{Altura}} \quad (1)$$

Estruturas compactas e preenchidas, como uma lesão focal, apresentam compacidade próxima de 1, enquanto estruturas

finas e alongadas, como o anel craniano ou os artefatos lineares da mesa, apresentam compacidade próxima de 0. Conforme a Tabela I, o candidato a tumor apresentou compacidade de 0,56, valor substancialmente superior ao das demais estruturas, permitindo sua seleção inequívoca (Fig. 5).




Fig. 5. (a) Imagem original em escala de cinza; (b) máscara do candidato a tumor identificado.

Investigou-se ainda o efeito do tamanho do elemento estruturante na etapa de abertura/fechamento. Com kernel de tamanho 15, os artefatos lineares da mesa são completamente eliminados pela erosão — por serem estruturas mais finas que o elemento estruturante — restando apenas o crânio e o candidato a tumor como componentes conexos. Entretanto, esse mesmo kernel também erodiu o candidato a tumor, reduzindo sua área de 502 para 384 px² (redução de aproximadamente 24%), conforme ilustrado na Fig. 6. Esse resultado evidencia um compromisso (*trade-off*): um elemento estruturante maior simplifica a etapa de seleção ao eliminar artefatos automaticamente, porém compromete a fidelidade geométrica da estrutura de interesse. Optou-se, portanto, por manter o elemento estruturante pequeno (3 × 3) e delegar a discriminação entre estruturas à métrica de compacidade, preservando a área original do candidato a tumor.




Fig. 6. Resultado da abertura e fechamento encadeados: (a) elemento estruturante 3 × 3; (b) elemento estruturante 15 × 15, eliminando os artefatos da mesa porém reduzindo a área do candidato a tumor.

É importante ressaltar que o resultado obtido constitui um *candidato* a lesão, fundamentado exclusivamente em critérios de intensidade e forma. Outras estruturas hiperdensas e focais, como calcificações ou hemorragias, produziram uma assi-

natura morfológica semelhante, de modo que o método não substitui uma avaliação diagnóstica.

B. Questão 2 — Segmentação por Cor via K-Means

1) *Preparação dos Dados e Escolha do Número de Clusters*: Para a segmentação por cor da imagem *onion.jpg*, cada pixel foi tratado como uma amostra em um espaço de características tridimensional, correspondente aos canais de cor (B, G, R). A imagem, originalmente uma matriz $H \times W \times 3$, foi reorganizada em uma matriz $(H \cdot W) \times 3$, formato exigido pelo algoritmo k-means.

O algoritmo k-means particiona as amostras em k grupos, atribuindo iterativamente cada ponto ao centróide mais próximo e recalculando os centróides como a média dos pontos atribuídos, até convergência. A escolha do número de clusters k foi determinada pelo método do cotovelo (*elbow method*), que analisa a curva de inércia — soma dos quadrados das distâncias intra-cluster (WCSS) — em função de k . Para automatizar a leitura do “cotovelo” da curva, calculou-se, para cada ponto, a distância perpendicular até a reta que une o primeiro e o último ponto da curva; o valor de k correspondente à maior distância foi selecionado como ótimo.




Fig. 7. Curva de inércia em função de k , com o ponto de cotovelo identificado em $k = 5$.

A aplicação desse critério à imagem de hortaliças resultou em $k = 5$ (Fig. 7), correspondendo ao ponto a partir do qual o ganho marginal de redução de inércia se torna pequeno frente ao aumento de complexidade do modelo.

Como análise complementar, calculou-se também o coeficiente de silhueta para o mesmo intervalo de k (Fig. 8). Diferentemente da inércia — que decresce monotonicamente com k por construção — a silhueta mede o quão bem separados os clusters estão entre si. Observou-se que a silhueta decresce de forma suave entre $k = 2$ e $k = 8$, sem apresentar um pico nítido em valores mais altos de k . Esse resultado indica que, do ponto de vista estritamente estatístico de separação de clusters, valores menores de k produzem agrupamentos mais coesos e bem delimitados, contrastando com a impressão visual de que valores maiores de k produzem segmentações “melhores”.

2) *Resultado da Segmentação e Análise de Sensibilidade a k* : Com $k = 5$, cada pixel foi reatribuído à cor média




Fig. 8. Coeficiente de silhueta em função de k .

(centróide) de seu cluster, produzindo a imagem segmentada da Fig. 9.



Fig. 9. (a) Imagem original; (b) imagem segmentada com $k = 5$.

Cabe destacar uma ressalva metodológica importante: como o k-means minimiza o erro de reconstrução, qualquer aumento em k reduz a inércia e aproxima a imagem segmentada da imagem original — no limite, com k igual ao número de pixels, o erro de reconstrução é nulo. Logo, uma maior fidelidade visual à imagem original não é, por si só, evidência de uma segmentação mais correta; é necessário avaliar se o aumento de k está separando objetos genuinamente distintos ou apenas fragmentando um mesmo objeto devido a variações de iluminação (sobre-segmentação).

Para investigar esse efeito, comparou-se o resultado para $k \in \{5, 7, 9, 11\}$ (Fig. 10). Constatou-se que, em $k = 5$, o pimentão amarelo é incorretamente agrupado na mesma cor que o alho e a couve-flor, hortaliças de cor e identidade claramente distintas. Em $k = 7$, essa fusão é corrigida, com o pimentão amarelo passando a ocupar um cluster próprio. A partir de $k = 9$, observa-se o início de sobre-segmentação no fundo da imagem, que passa a apresentar uma textura ruidosa decorrente de variações sutis de iluminação, sem corresponder a nenhuma nova hortaliça. Em $k = 11$, a cenoura é finalmente separada do vermelho do pimentão/tomate — uma separação semanticamente válida — mas ao custo de um fundo ainda mais fragmentado.

Esses resultados ilustram uma tensão geral entre o critério estatístico de seleção de k (cotovelo e silhueta, que favorecem valores menores) e o objetivo semântico do enunciado — segmentar cada hortaliça individualmente —, que exigiria um



Fig. 10. Sensibilidade da segmentação ao número de clusters: $k = 5, 7, 9$ e 11 .

valor de k ligeiramente maior. Mantém-se $k = 5$ como resultado oficial do método algorítmico empregado, mas destaca-se $k = 7$ como um refinamento qualitativo razoável, que corrige a fusão observada sem incorrer ainda na sobre-segmentação do fundo presente a partir de $k = 9$.

III. CONCLUSÃO

Este relatório técnico evidenciou os desafios práticos de duas técnicas clássicas de segmentação em PDI. Na primeira etapa, demonstrou-se que a filtragem espacial prévia, embora imperceptível na imagem em escala de cinza, é determinante para a qualidade da binarização subsequente, reduzindo drasticamente o número de componentes conexos espúrios. Constatou-se ainda que o critério ingênuo de seleção pela maior área conexa falha sistematicamente nesta aplicação, por favorecer estruturas anatômicas extensas (o crânio) e artefatos de aquisição sobre a lesão de interesse; a introdução de uma métrica de compacidade revelou-se necessária e suficiente para a discriminação correta. Por fim, evidenciou-se um compromisso entre o tamanho do elemento estruturante morfológico e a fidelidade geométrica da estrutura segmentada.

Na segunda etapa, o método do cotovelo forneceu uma estimativa automática e reprodutível do número de clusters ($k = 5$) para a segmentação por cor via k-means. A análise complementar de silhueta e a inspeção qualitativa de valores vizinhos de k revelaram, contudo, que a escolha ótima sob o ponto de vista estatístico não coincide necessariamente com a granularidade semântica desejada, ilustrando uma limitação intrínseca de métodos de agrupamento não supervisionado quando aplicados a problemas com significado semântico definido pelo usuário.

Conclui-se que, em ambos os casos, a aplicação direta dos algoritmos clássicos de PDI — conforme sugerido em sua forma mais simples — não foi suficiente para produzir o resultado desejado, sendo necessária uma camada adicional de análise crítica e métricas auxiliares para validar e refinar os resultados obtidos.

REFERENCES

- [1] R. C. Gonzalez e R. E. Woods, *Processamento Digital de Imagens*, 3ª ed. São Paulo, Brasil: Pearson Prentice Hall, 2010.
- [2] G. Bradski, “The OpenCV Library”, *Dr. Dobbs Journal of Software Tools*, 2000. [Online]. Disponível: <https://opencv.org/>
- [3] C. R. Harris *et al.*, “Array programming with NumPy”, *Nature*, vol. 585, pp. 357–362, Set. 2020. doi: 10.1038/s41586-020-2649-2.
- [4] J. D. Hunter, “Matplotlib: A 2D graphics environment”, *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, Maio 2007. doi: 10.1109/MCSE.2007.55.
- [5] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python”, *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

- [6] N. Otsu, "A threshold selection method from gray-level histograms", *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979. doi: 10.1109/TSMC.1979.4310076.